Gruppo 2

Student Burnout & Dropout Risk Dataset

Esplorazione, analisi e modelli predittivi

Presentato da: Antonio, Federica, Massimo, Yuri

Indice

Esplorazione dati

Variabili target:

1. Burnout level (High, Medium,Low)
2. Drop out Risk (Yes, No)

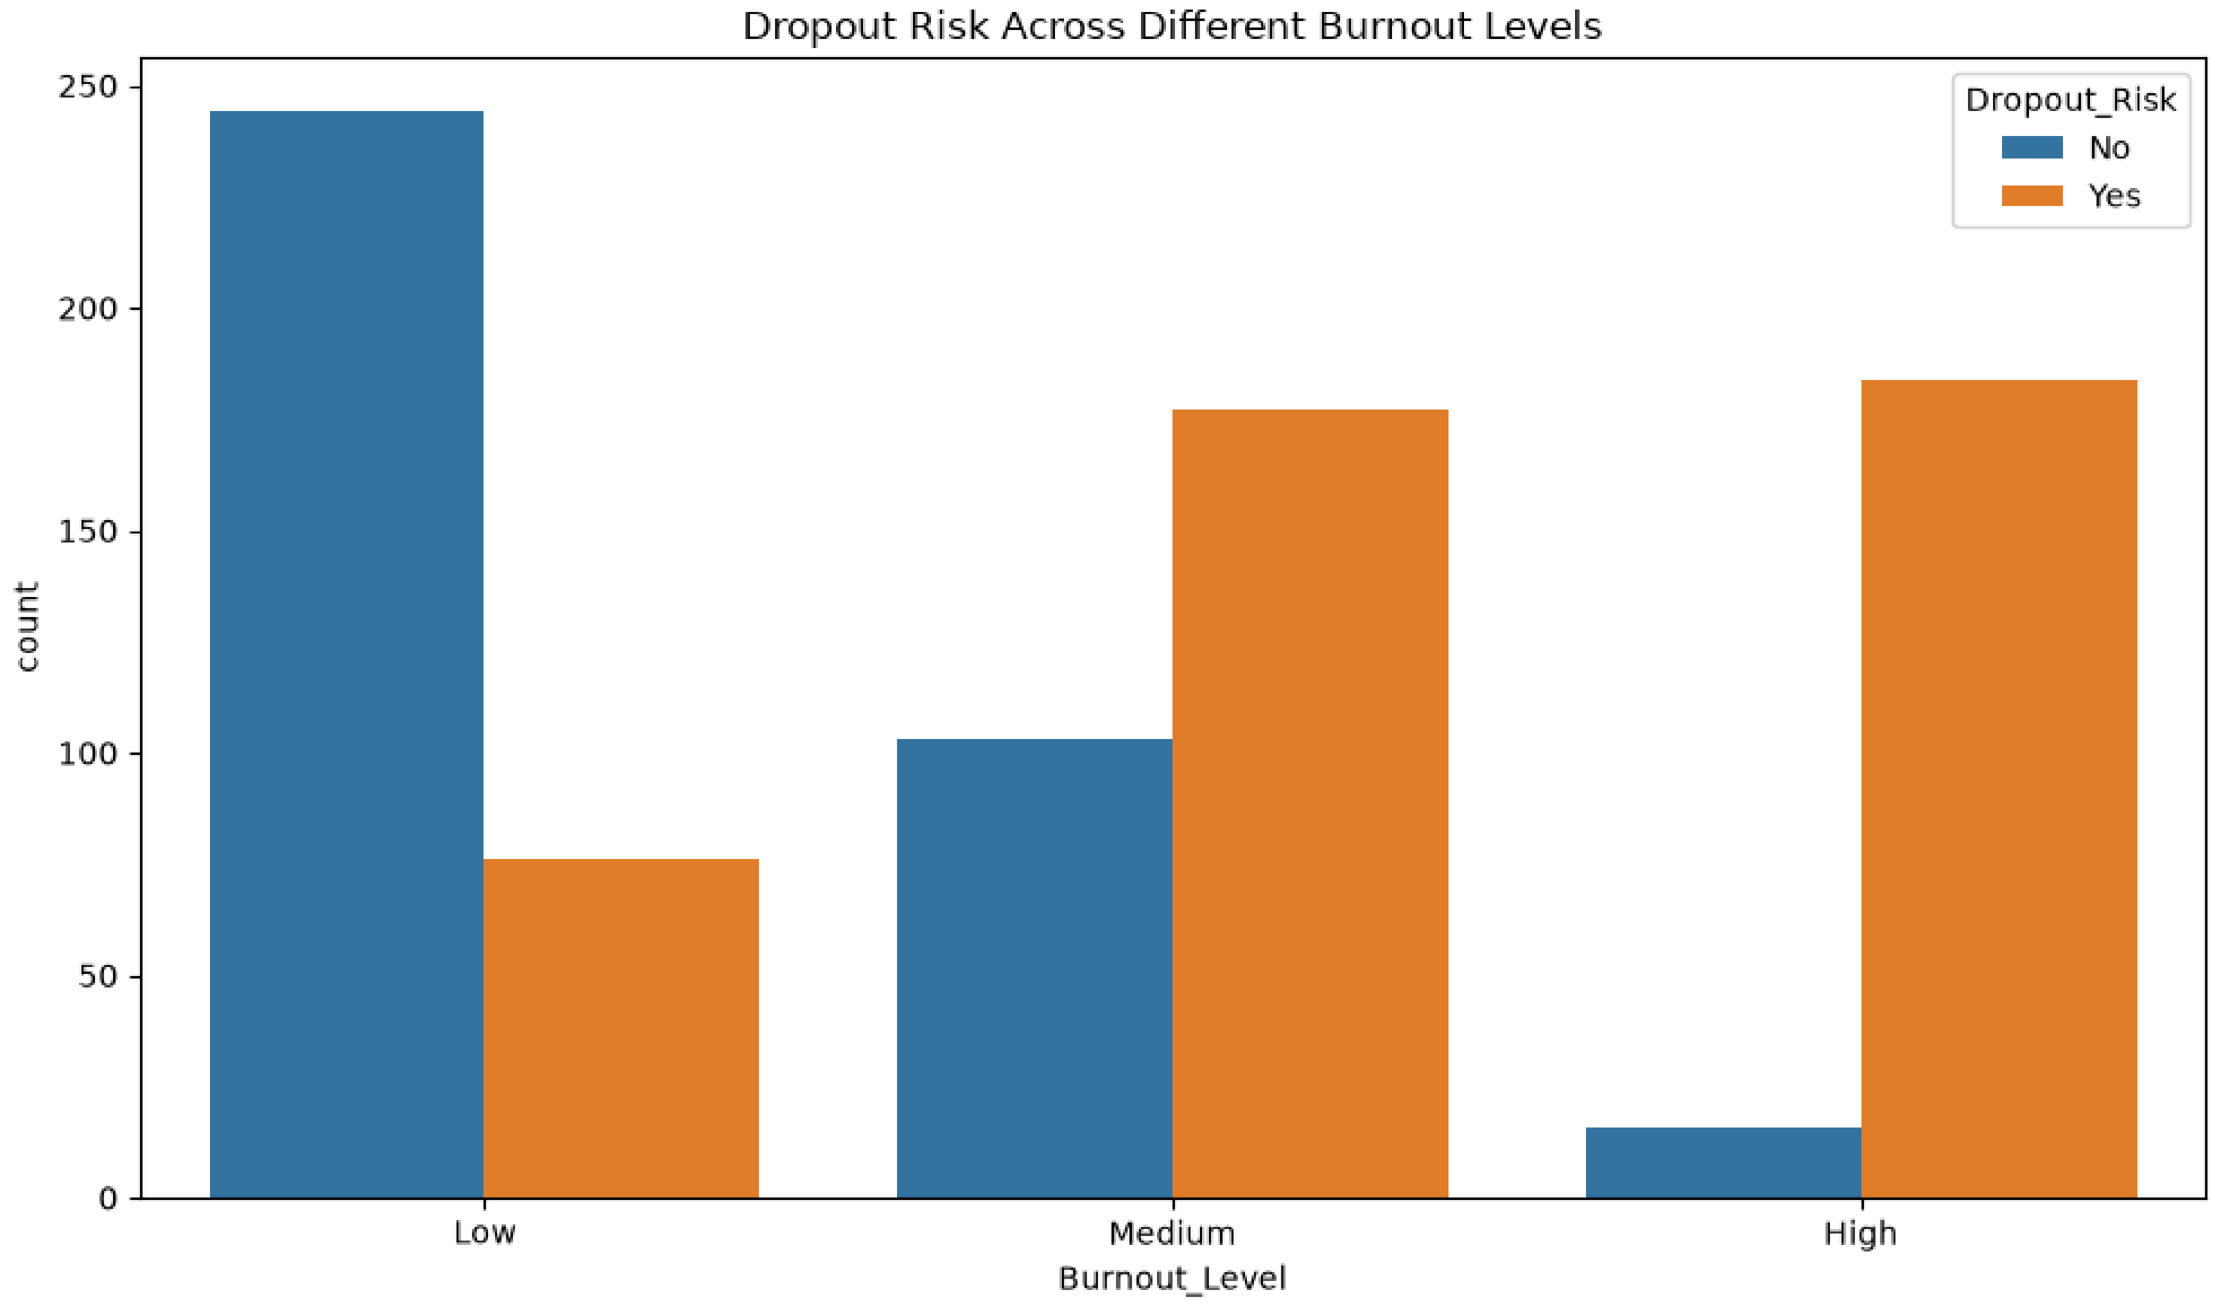

Boxplot
Relazioni più significative

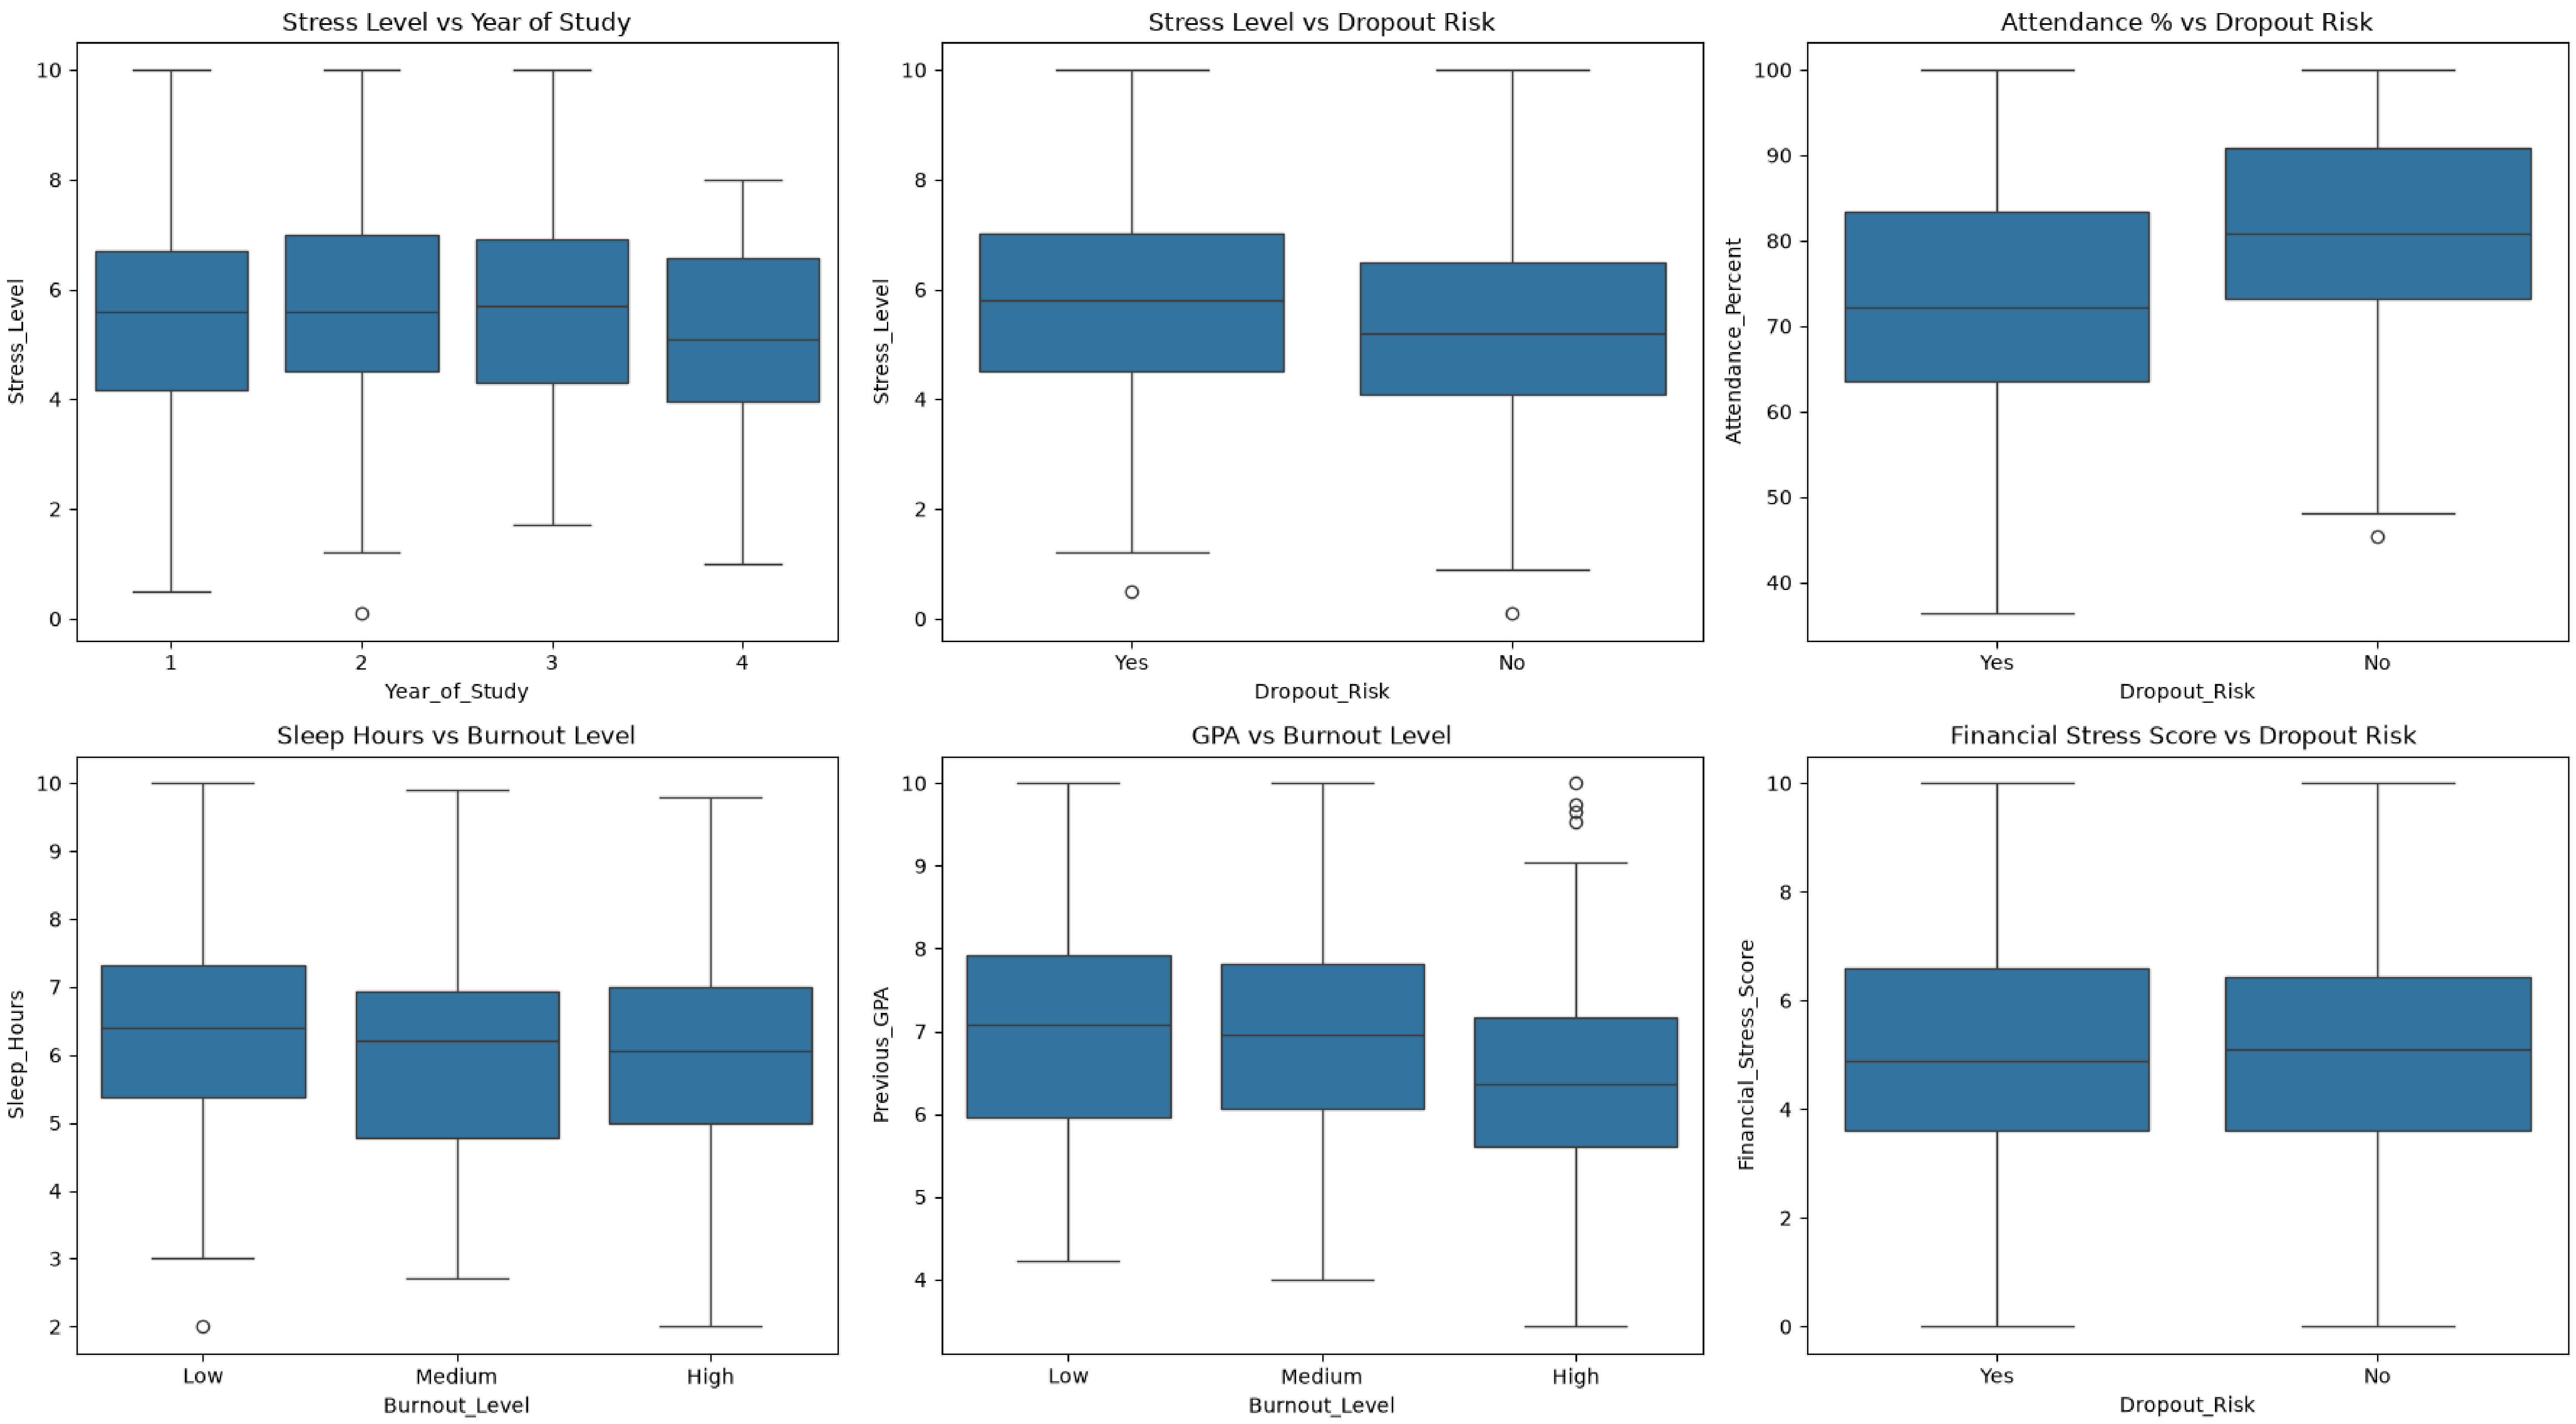

Matrice di correlazione

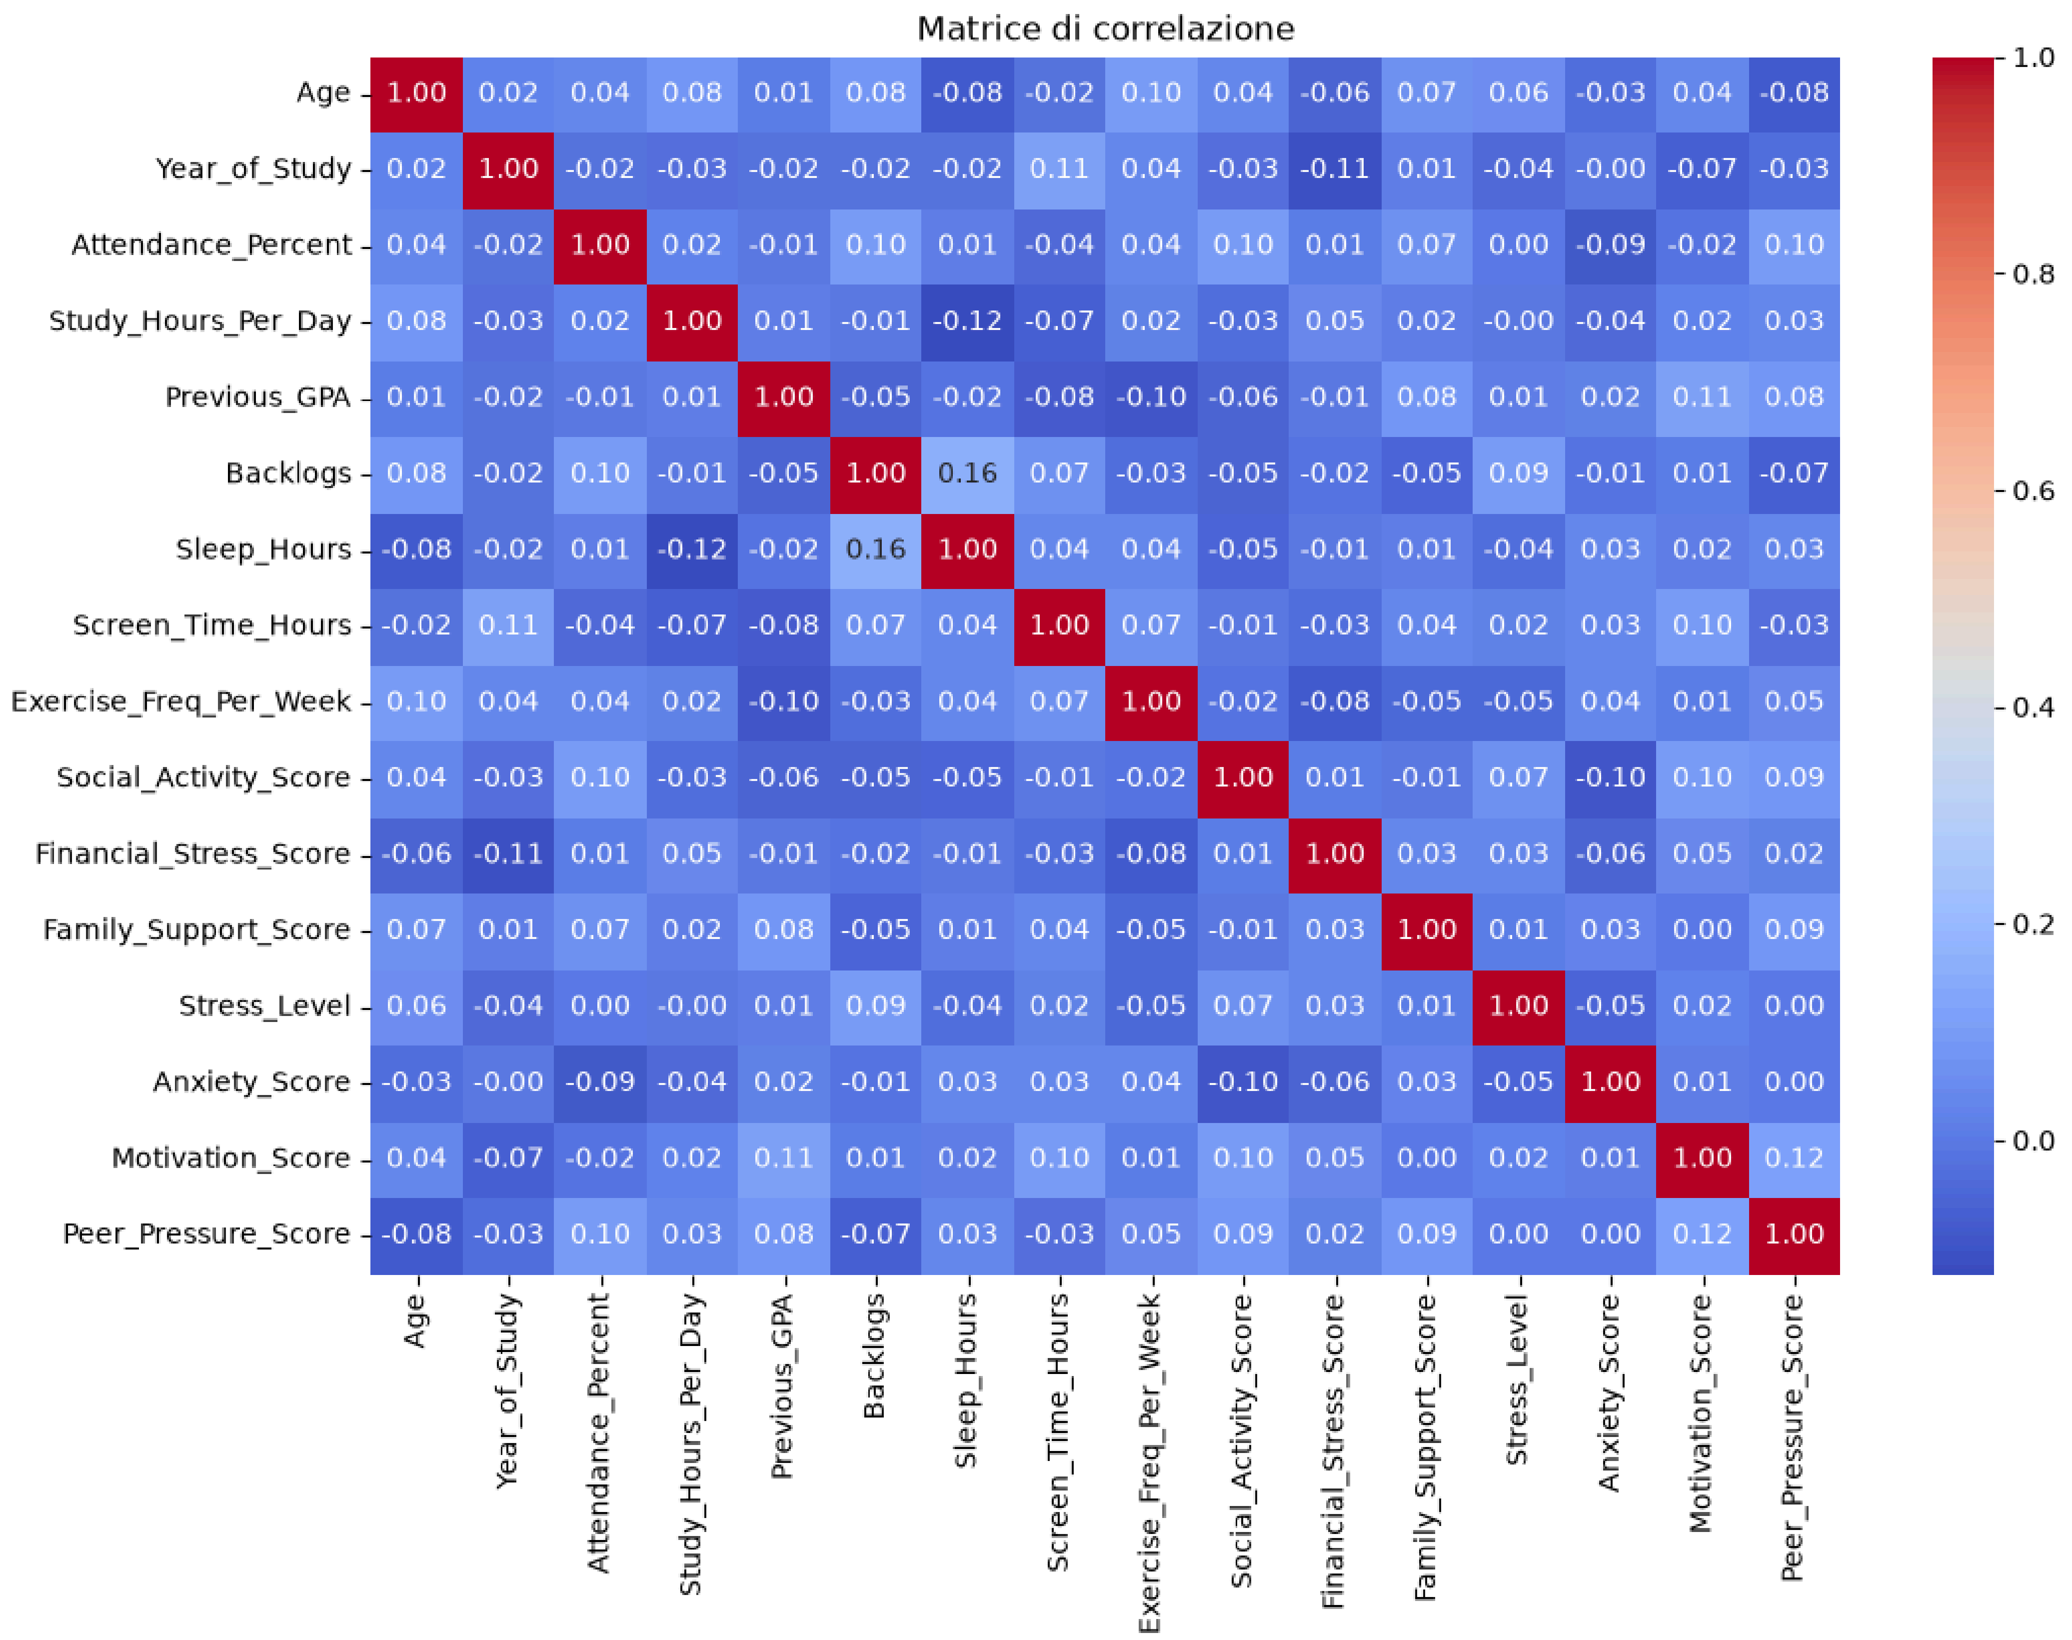

Istogrammi

Diagrammi per anni di studio e arretrati

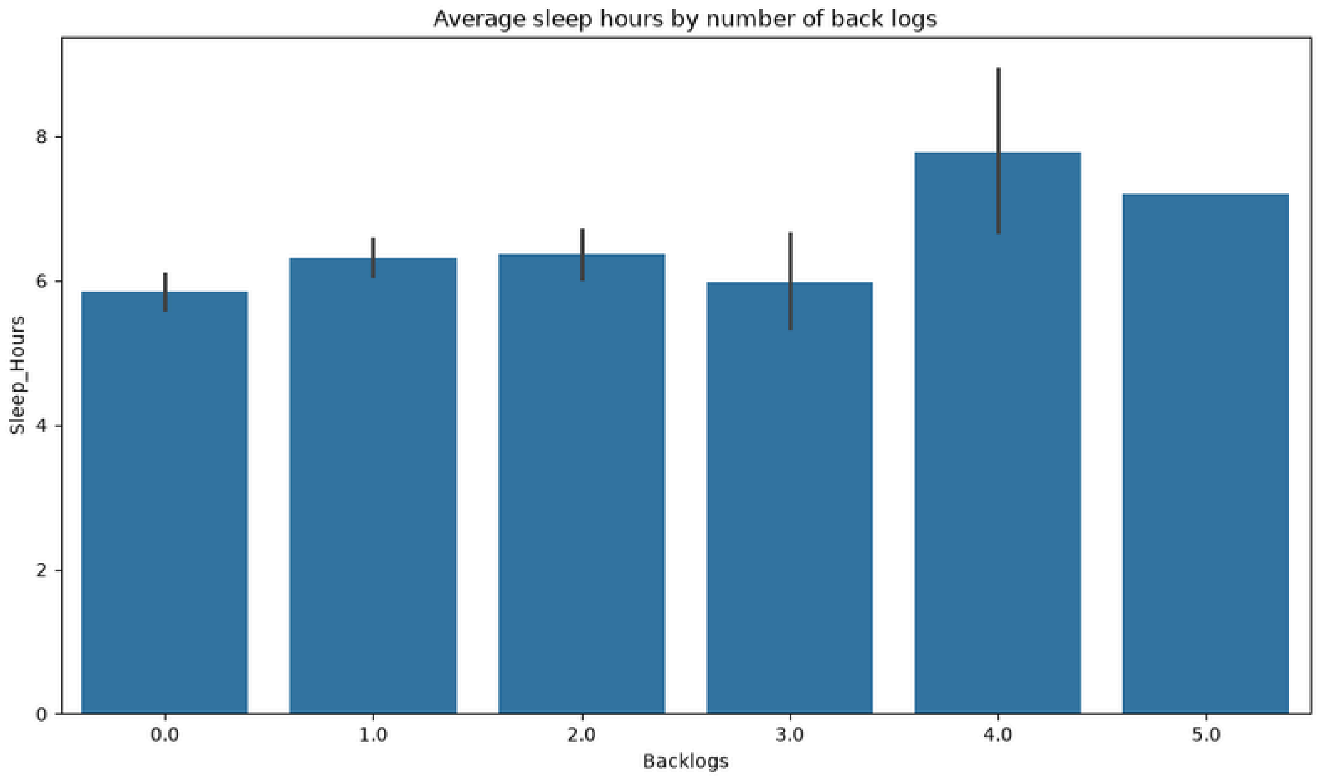

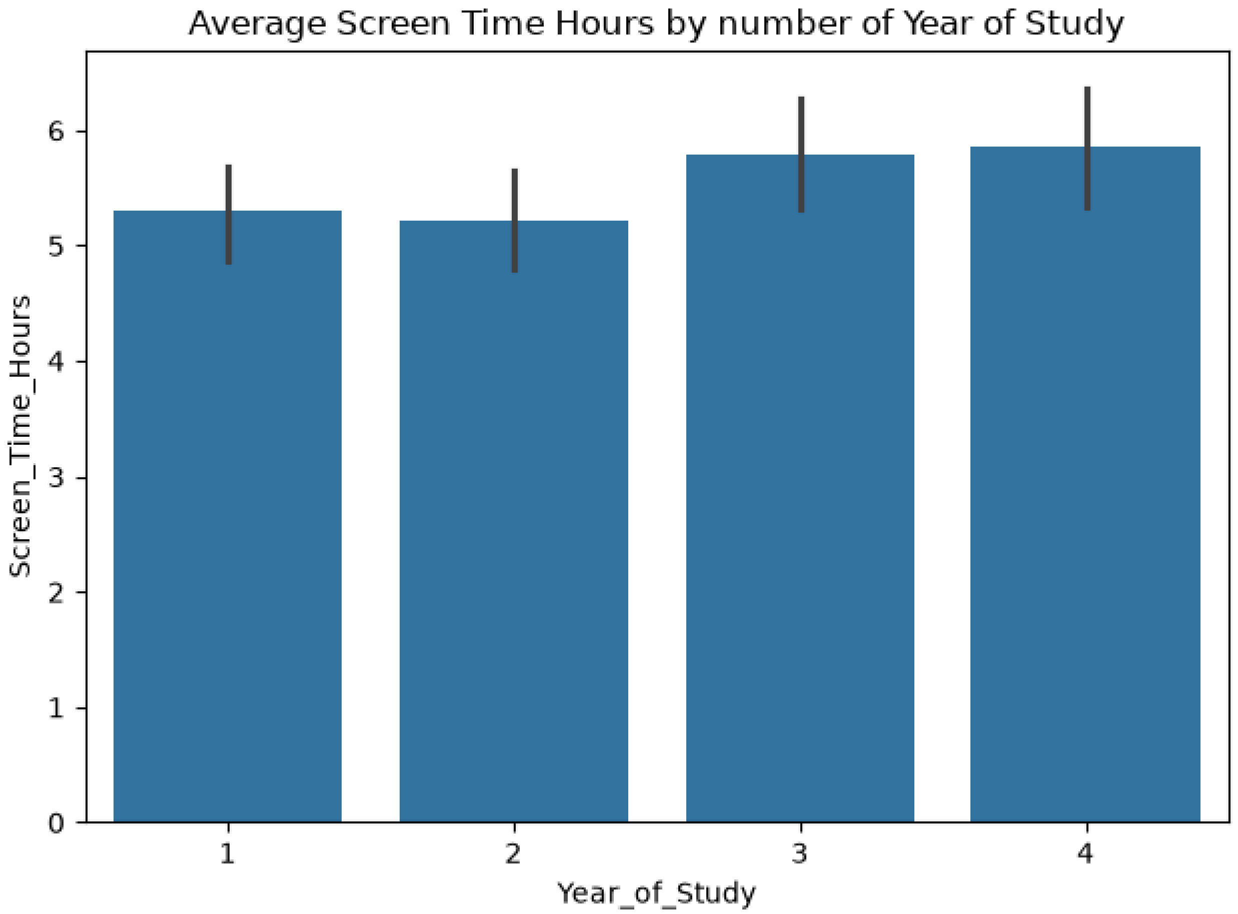

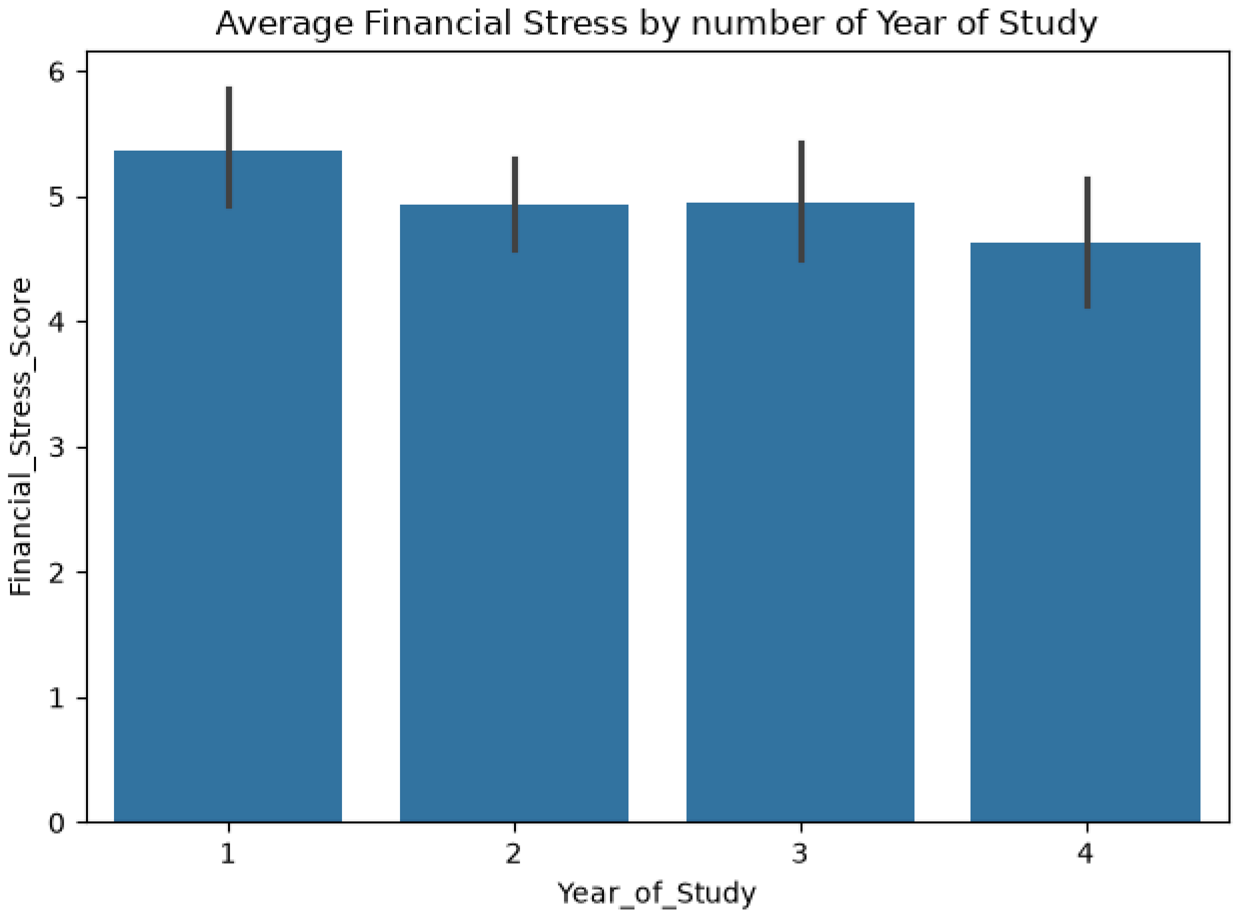

Grafici a dispersione

Diagrammi delle relazioni a più alta correlazione

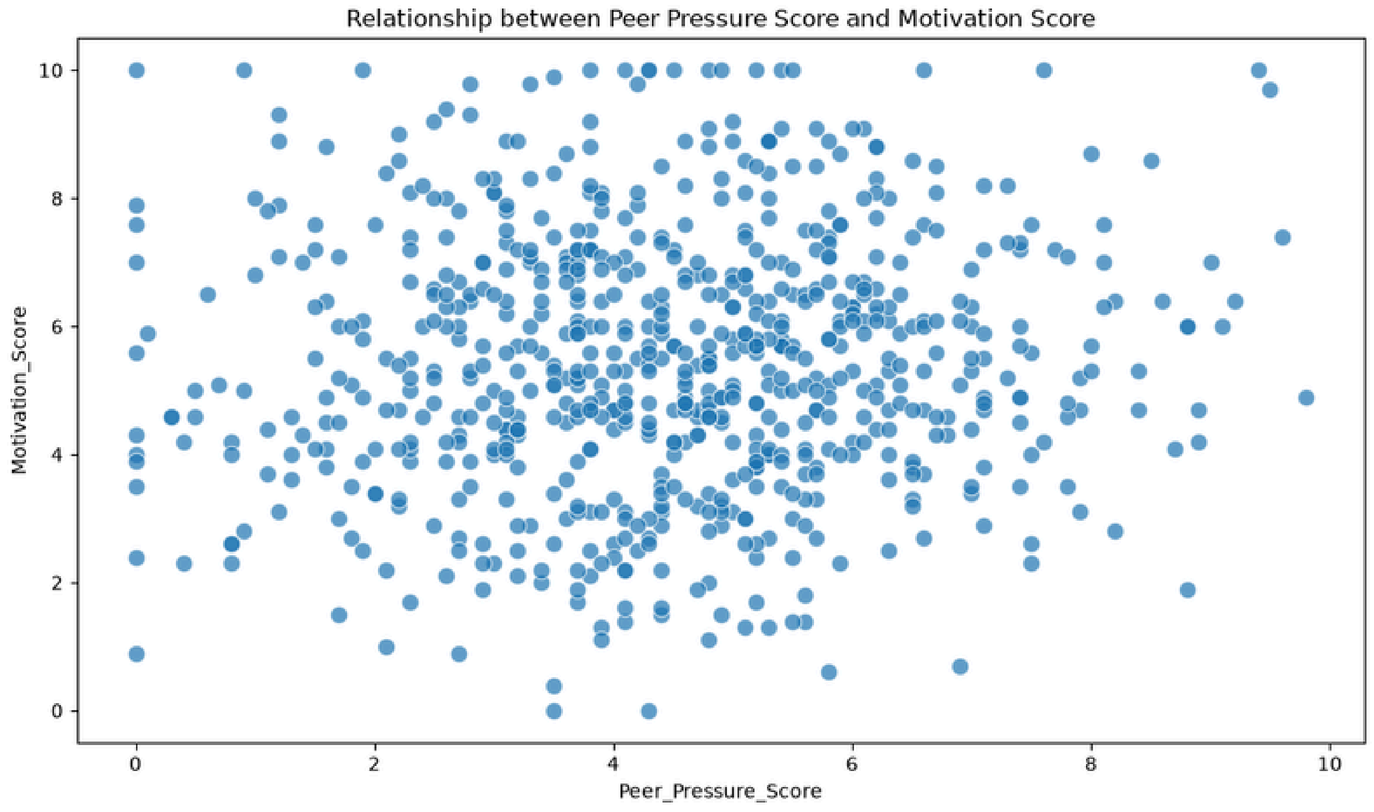

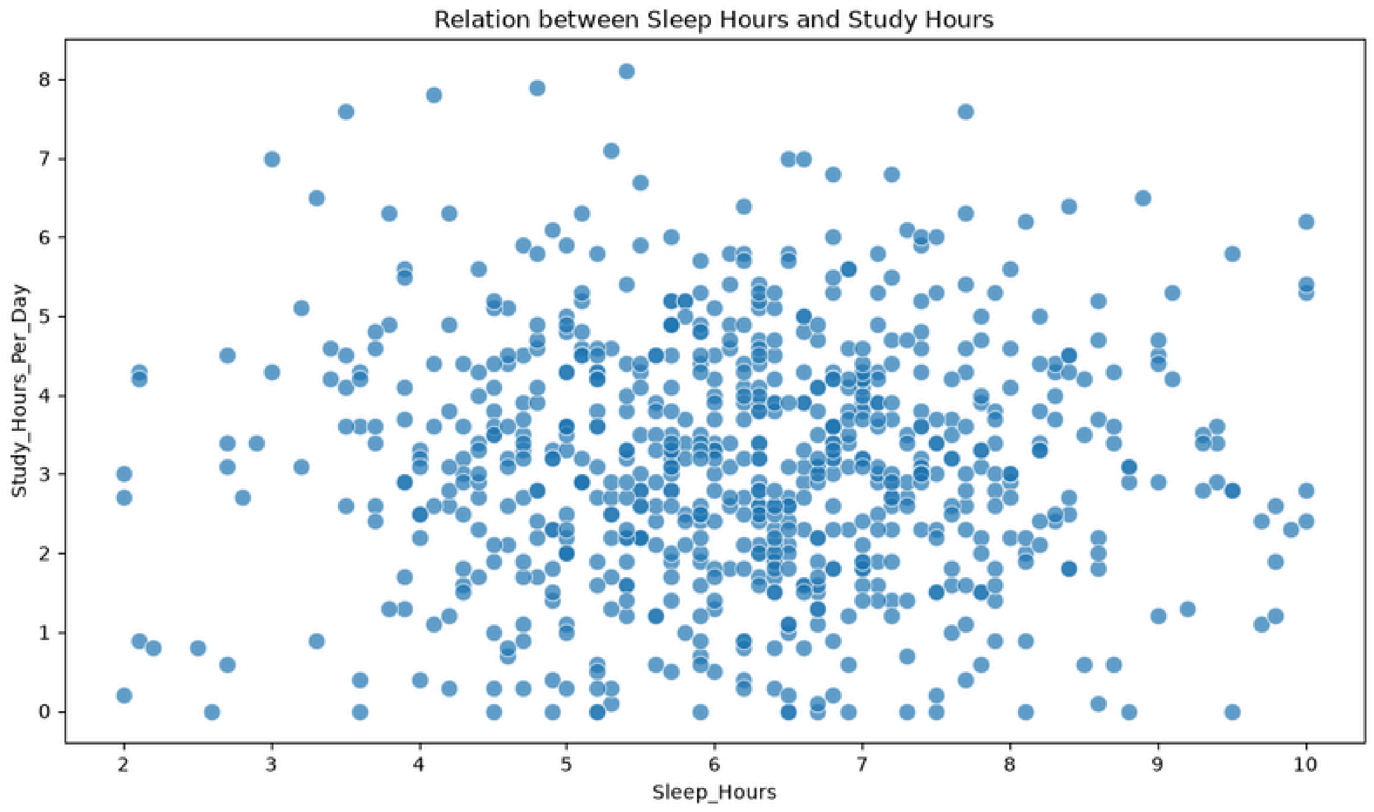

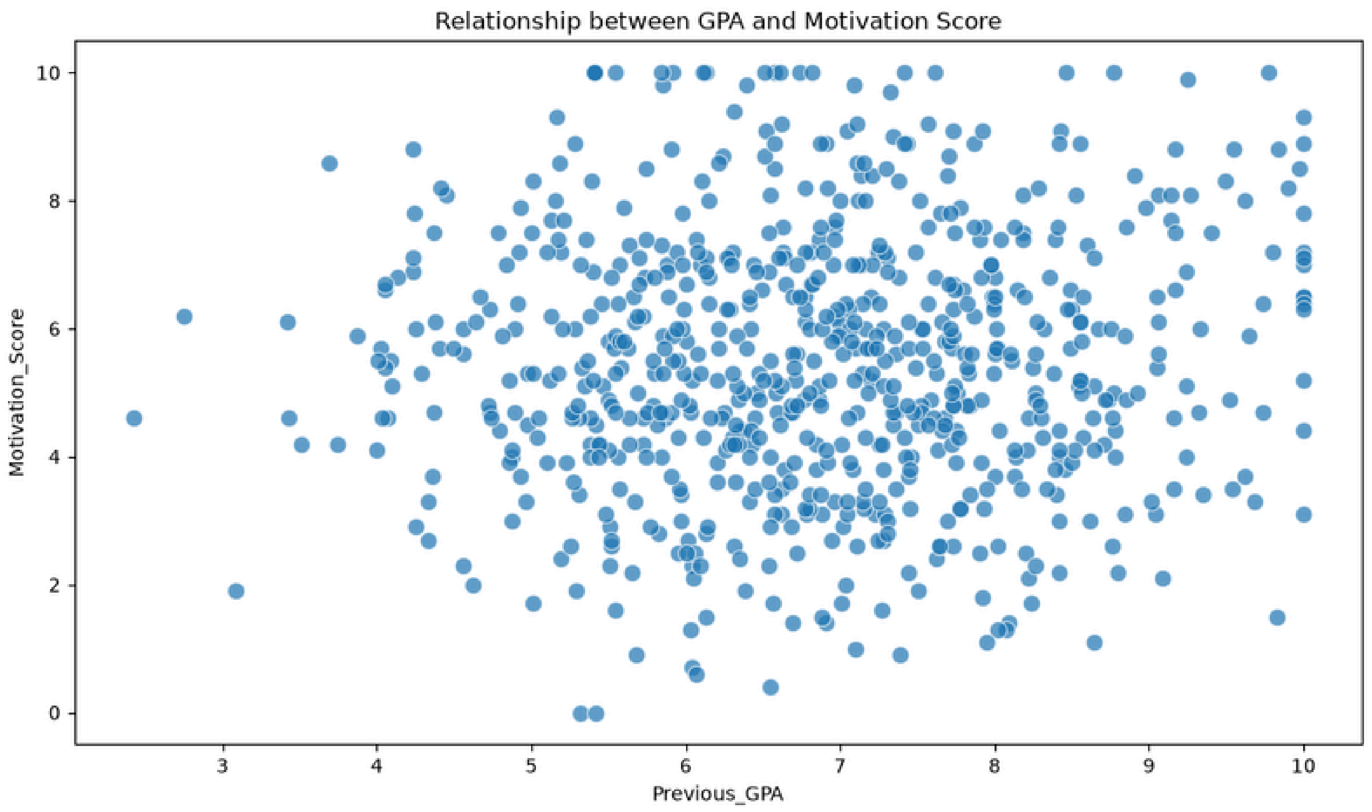

Dashboard con PowerBi

01

Pulizia dati

Sostituzione valori
Creazione colonne condizionali
Eliminazione dei valori mancanti

02

Definizione misure

N. studenti totali
N. studenti a rischio di drop out
N. studenti con alto livello di burnout

03

Inserimento grafici di interesse per l’analisi

Overview sulla composizione dei corsi di laurea
Focus salute mentale
Focus livello di motivazione
Valori utili per l’intervento

Script di raggruppamento

tramite DataBricks e Spark

```
from pyspark.sql.functions import *
from pyspark.sql.types import *

path =
"/Volumes/workspace/default/dataset/student_burnout_dropout_data
set_2.csv"

df = spark.read.csv(path, header=True, inferSchema=True)


df_dropped = df.na.drop()   #pulizia del dataset, sono stati
eliminati tutti i null

df_chained = (
    df_dropped.groupBy(col("Department"), col ("Year_of_Study"),
col("Gender"), col("Burnout_Level"))
    .agg(count(col("student_id")).alias("n_student"))
    .sort(col("Department"), col("Year_of_Study"),
col("Gender"), col("Burnout_Level")
))

display(df_chained)
```

Department	Year_of_Study	Gender	Burnout_Level	n_student
Arts	1	Female	High	2
Arts	1	Female	Low	6
Arts	1	Female	Medium	5
Arts	1	Male	High	2
Arts	1	Male	Low	4
Arts	1	Male	Medium	1
Arts	1	Other	High	1
Arts	2	Female	High	3

...

Engineering	4	Male	High	2
Engineering	4	Male	Low	4
Engineering	4	Male	Medium	2
Engineering	4	Other	Low	1
Law	1	Female	High	1
Law	1	Female	Low	3
Law	1	Male	High	2
Law	1	Male	Low	1
Law	1	Male	Medium	1

Machine Learning

01

Definizione della struttura dati e operazioni di etichettatura, pulizia e standardizzazione

02

Implementazione dei principali metodi di classificazione su le due variabili target

03

Valutazione dell'accuratezza del modello e successiva ottimizzazione

01 Focus sulle operazioni iniziali

```
1. Importo il dataset
df = pd.read_csv('student_burnout_dropout_dataset_2.csv')
df_clean = df.dropna()
df_clean = df_clean.drop(columns=['Student_ID'])
print(df_clean['Dropout_Risk'].value_counts(normalize=True) * 100)  #distribuzione della colonna target Dropout_Risk
print(df_clean['Burnout_Level'].value_counts(normalize=True) * 100)  #distribuzione della colonna target Burnout_Level

2. Trasformazione delle variabili categoriche
cat_cols = df_clean.select_dtypes(include='str').columns    #seleziono le colonne categoriche
for column in cat_cols:
    le = LabelEncoder()
    df_clean[column] = le.fit_transform(df_clean[column])
3. Definizione delle variabili target e esplicative
X = df_clean.drop(columns=['Dropout_Risk', 'Burnout_Level'])  #rimuovo le colonne target
y_1 = df_clean['Dropout_Risk']  #colonna target per il dropout
y_2 = df_clean['Burnout_Level']  #colonna target per il burnout

4. Standardizzazione delle variabili indipendenti
scaler = StandardScaler()
X = scaler.fit_transform(X)
```

02

Focus sui modelli scelti

	Burnout Level	Dropout Risk
Classification Tree		✓
Random Forest	✓	
SVC		✓
Gradient Boosting	✓	
Logistic Regression		✓
KNN Classifier	✓	

3.1 Classification Tree

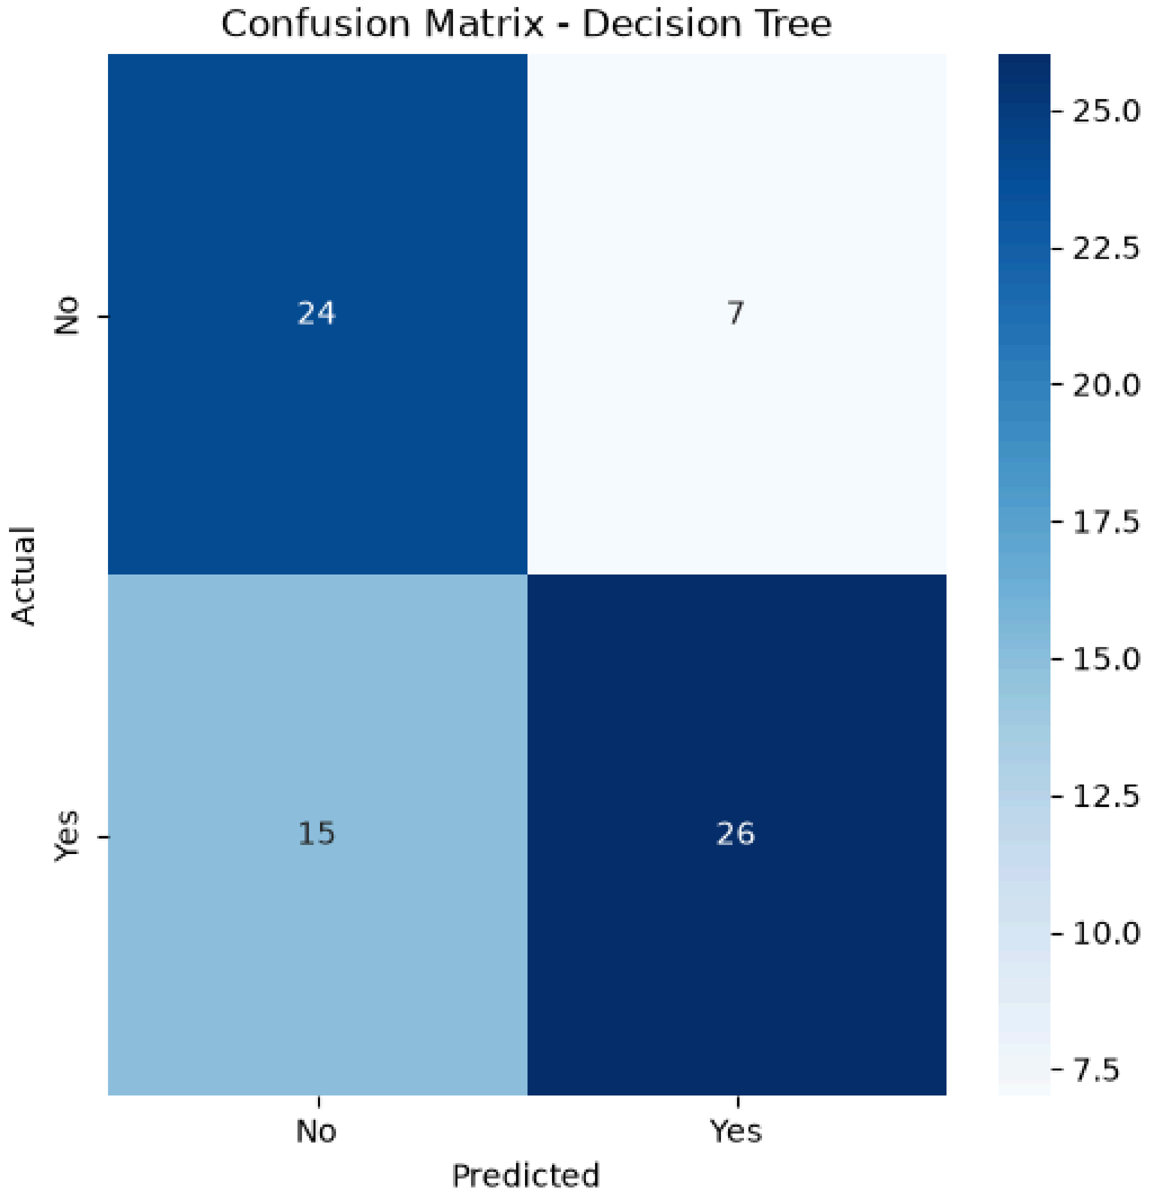

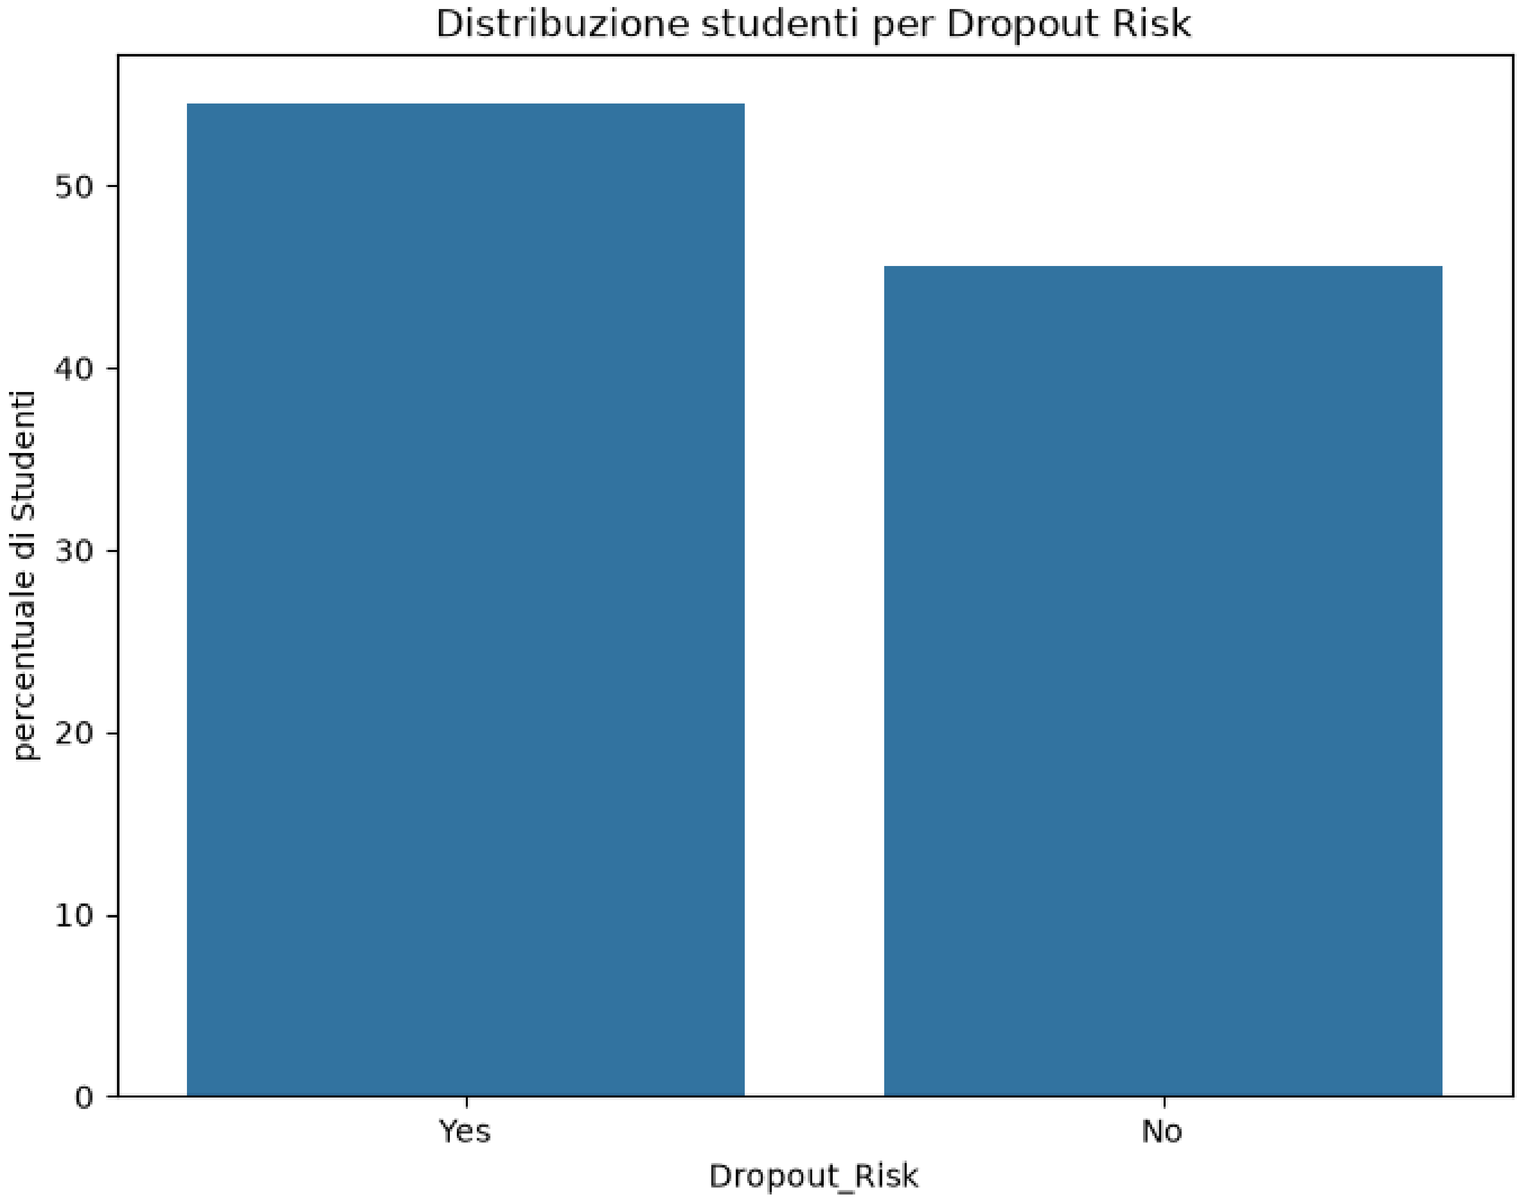

Accuracy level: 0.69

3.2 SVC

Prima dell’ottimizzazione

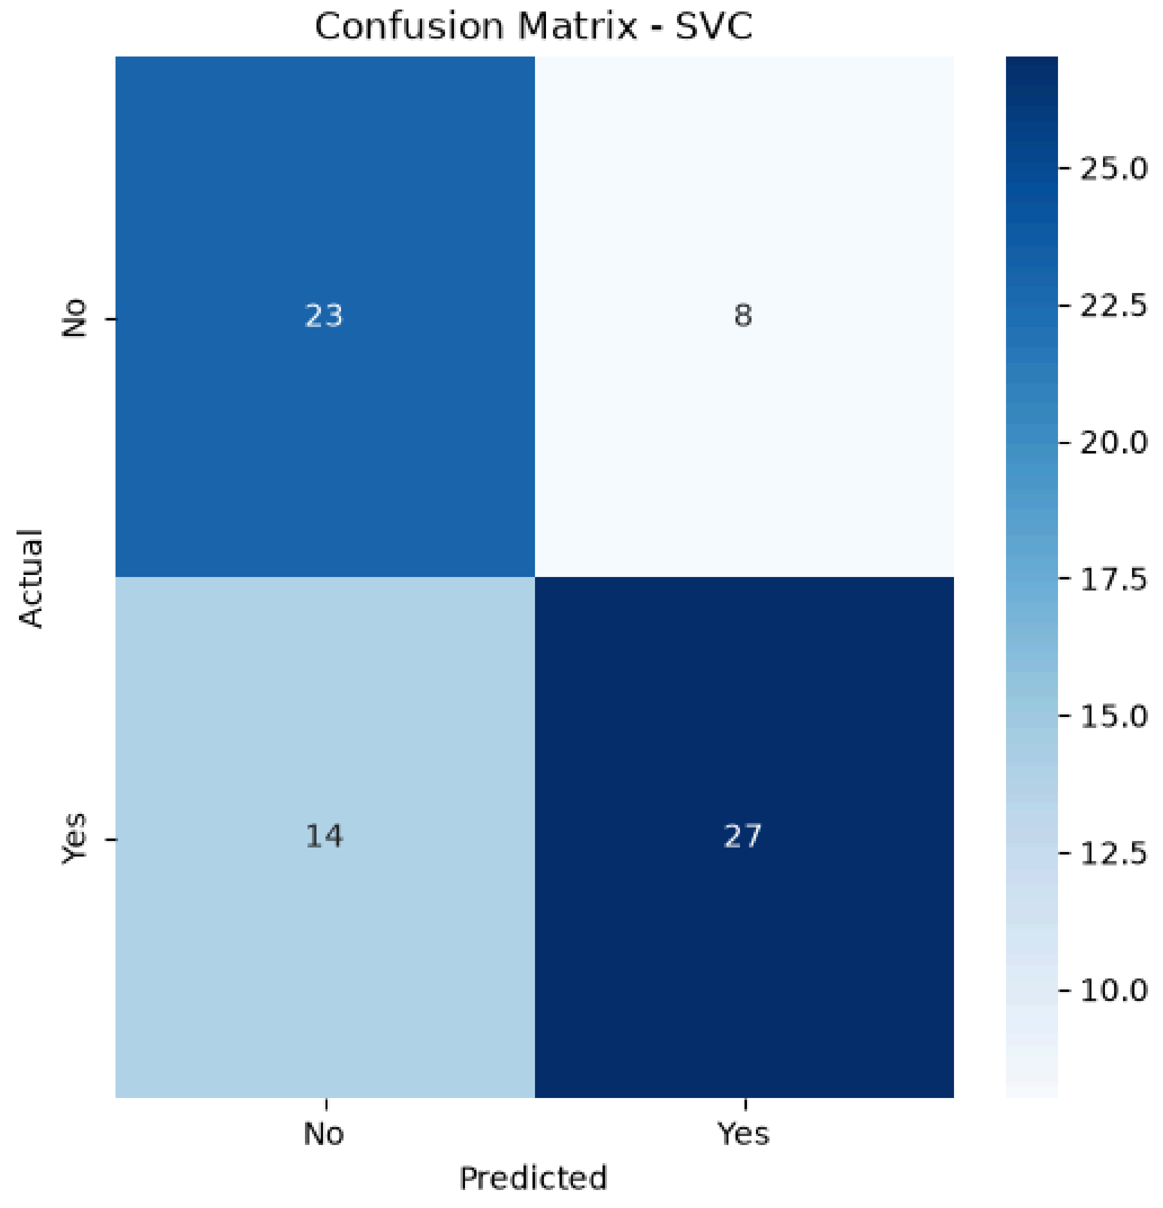

Accuracy level: 0.69

Dopo l’ottimizzazione

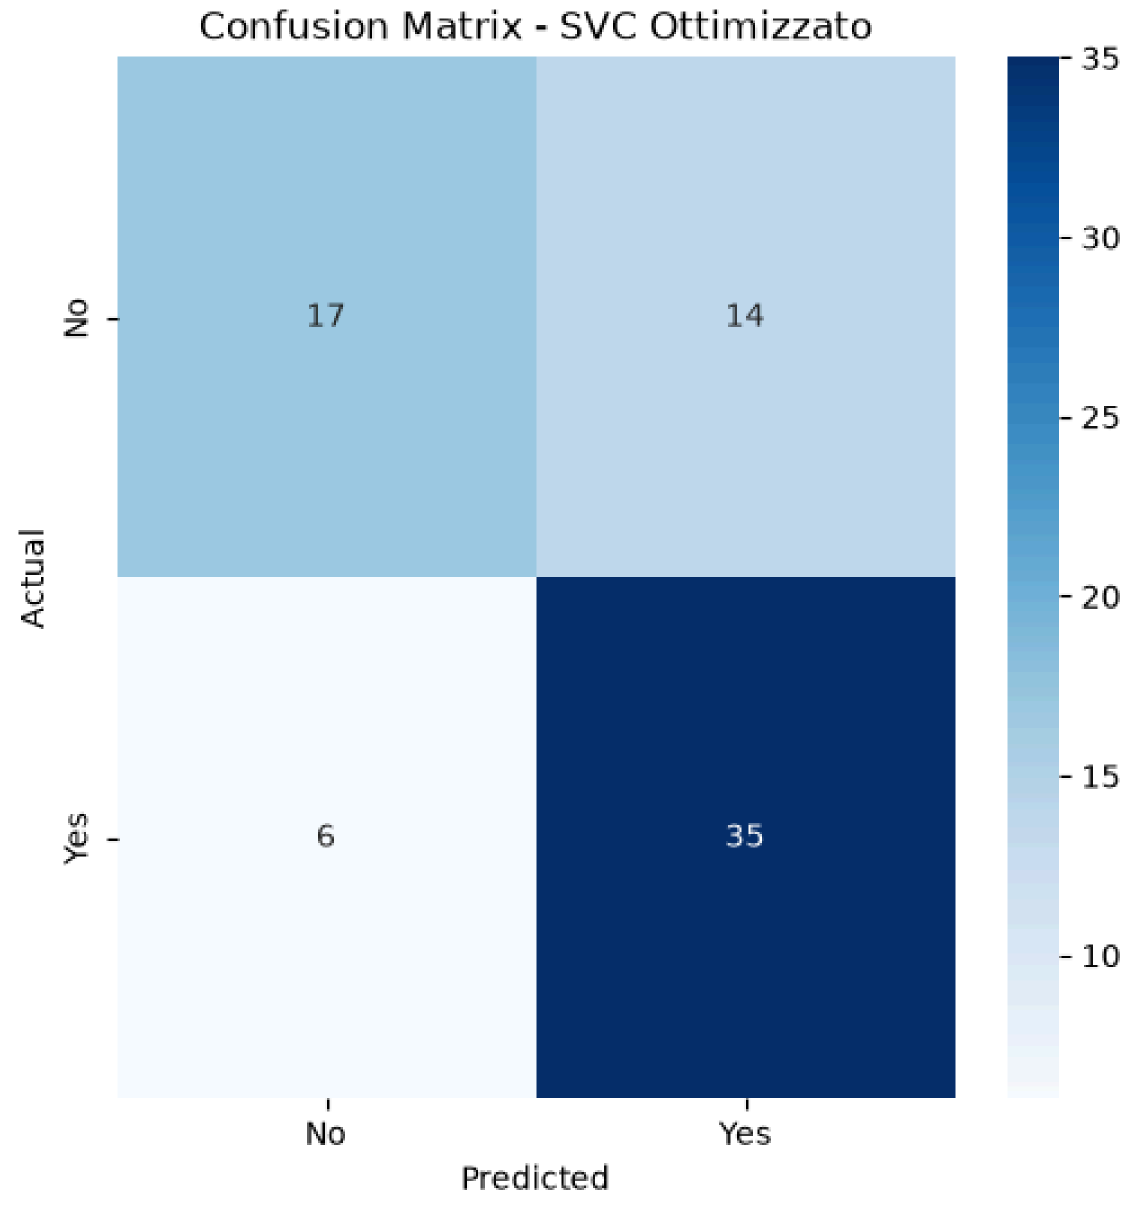

Accuracy level: 0.72

3.3 Gradient Boosting

0 Low 1 Medium 2 High

Prima dell'ottimizzazione

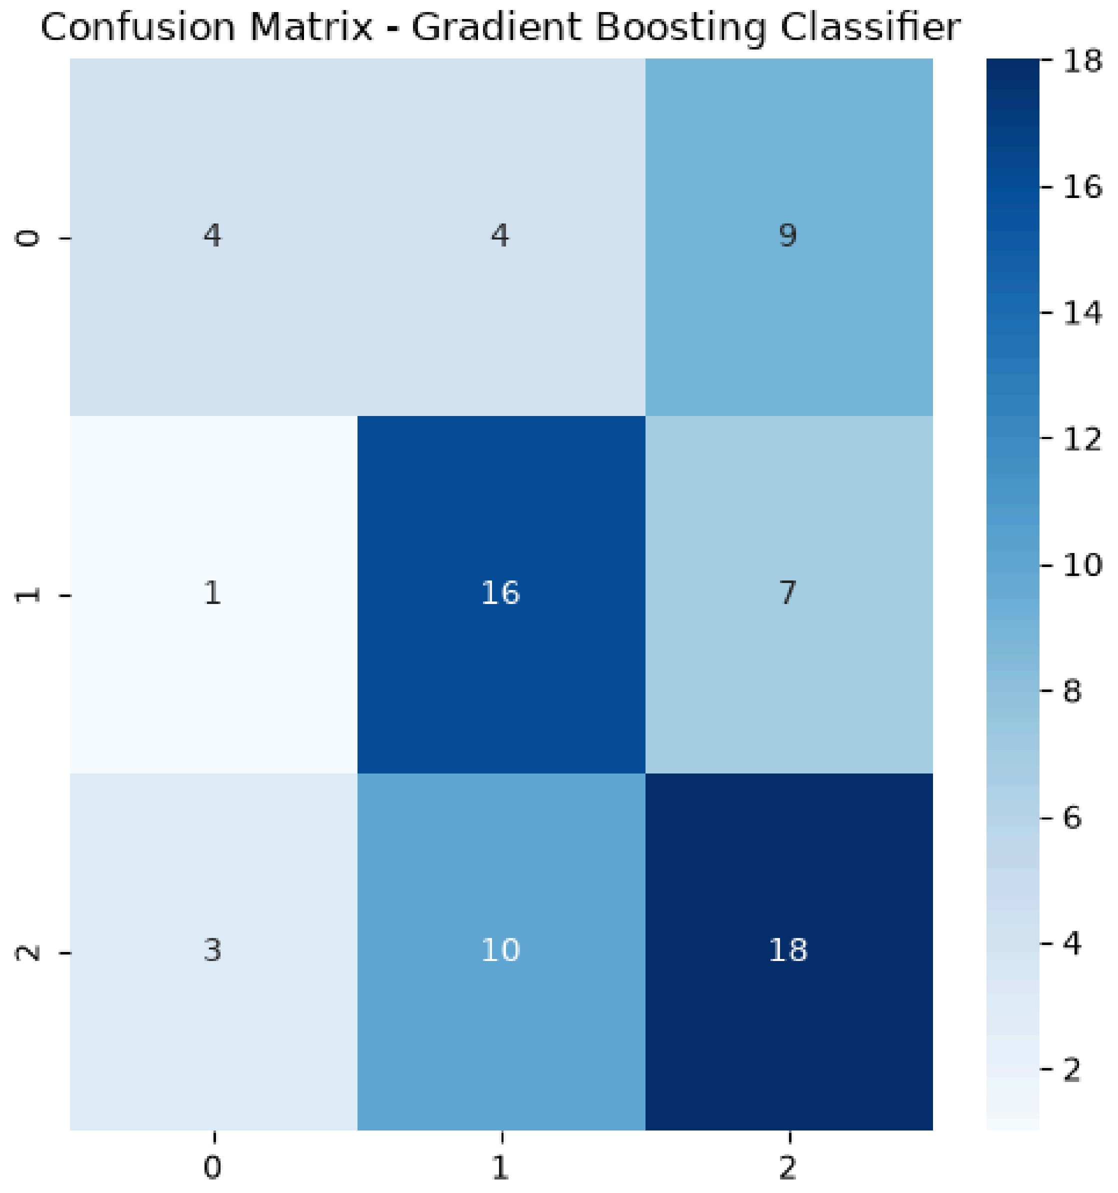

Accuracy level: 0.52

Dopo l'ottimizzazione

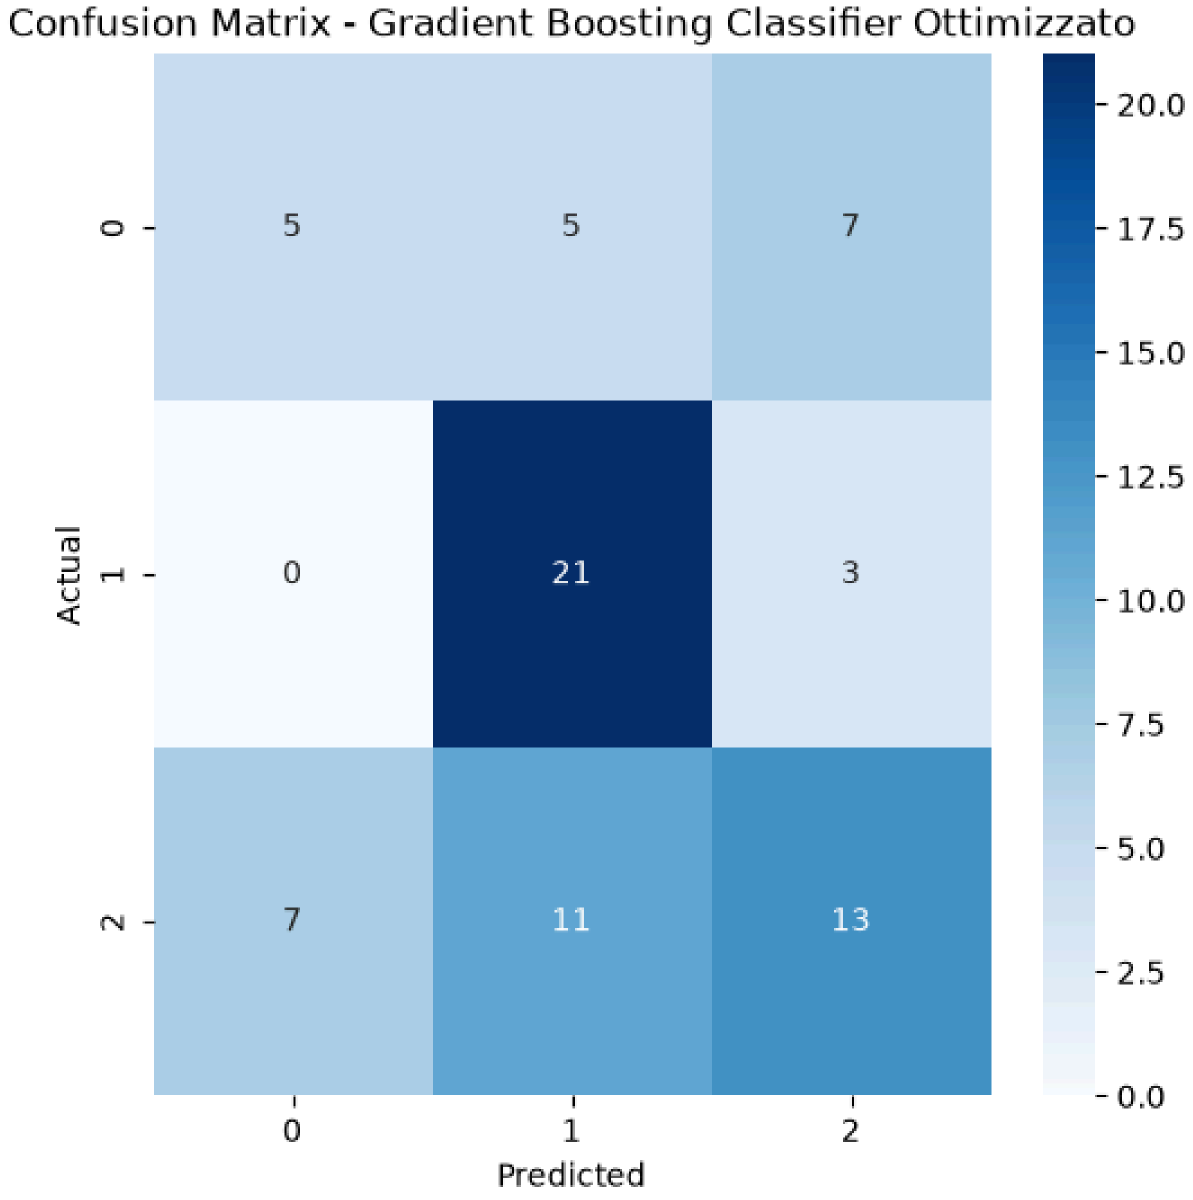

Accuracy level: 0.54

Database relazionale con SQL

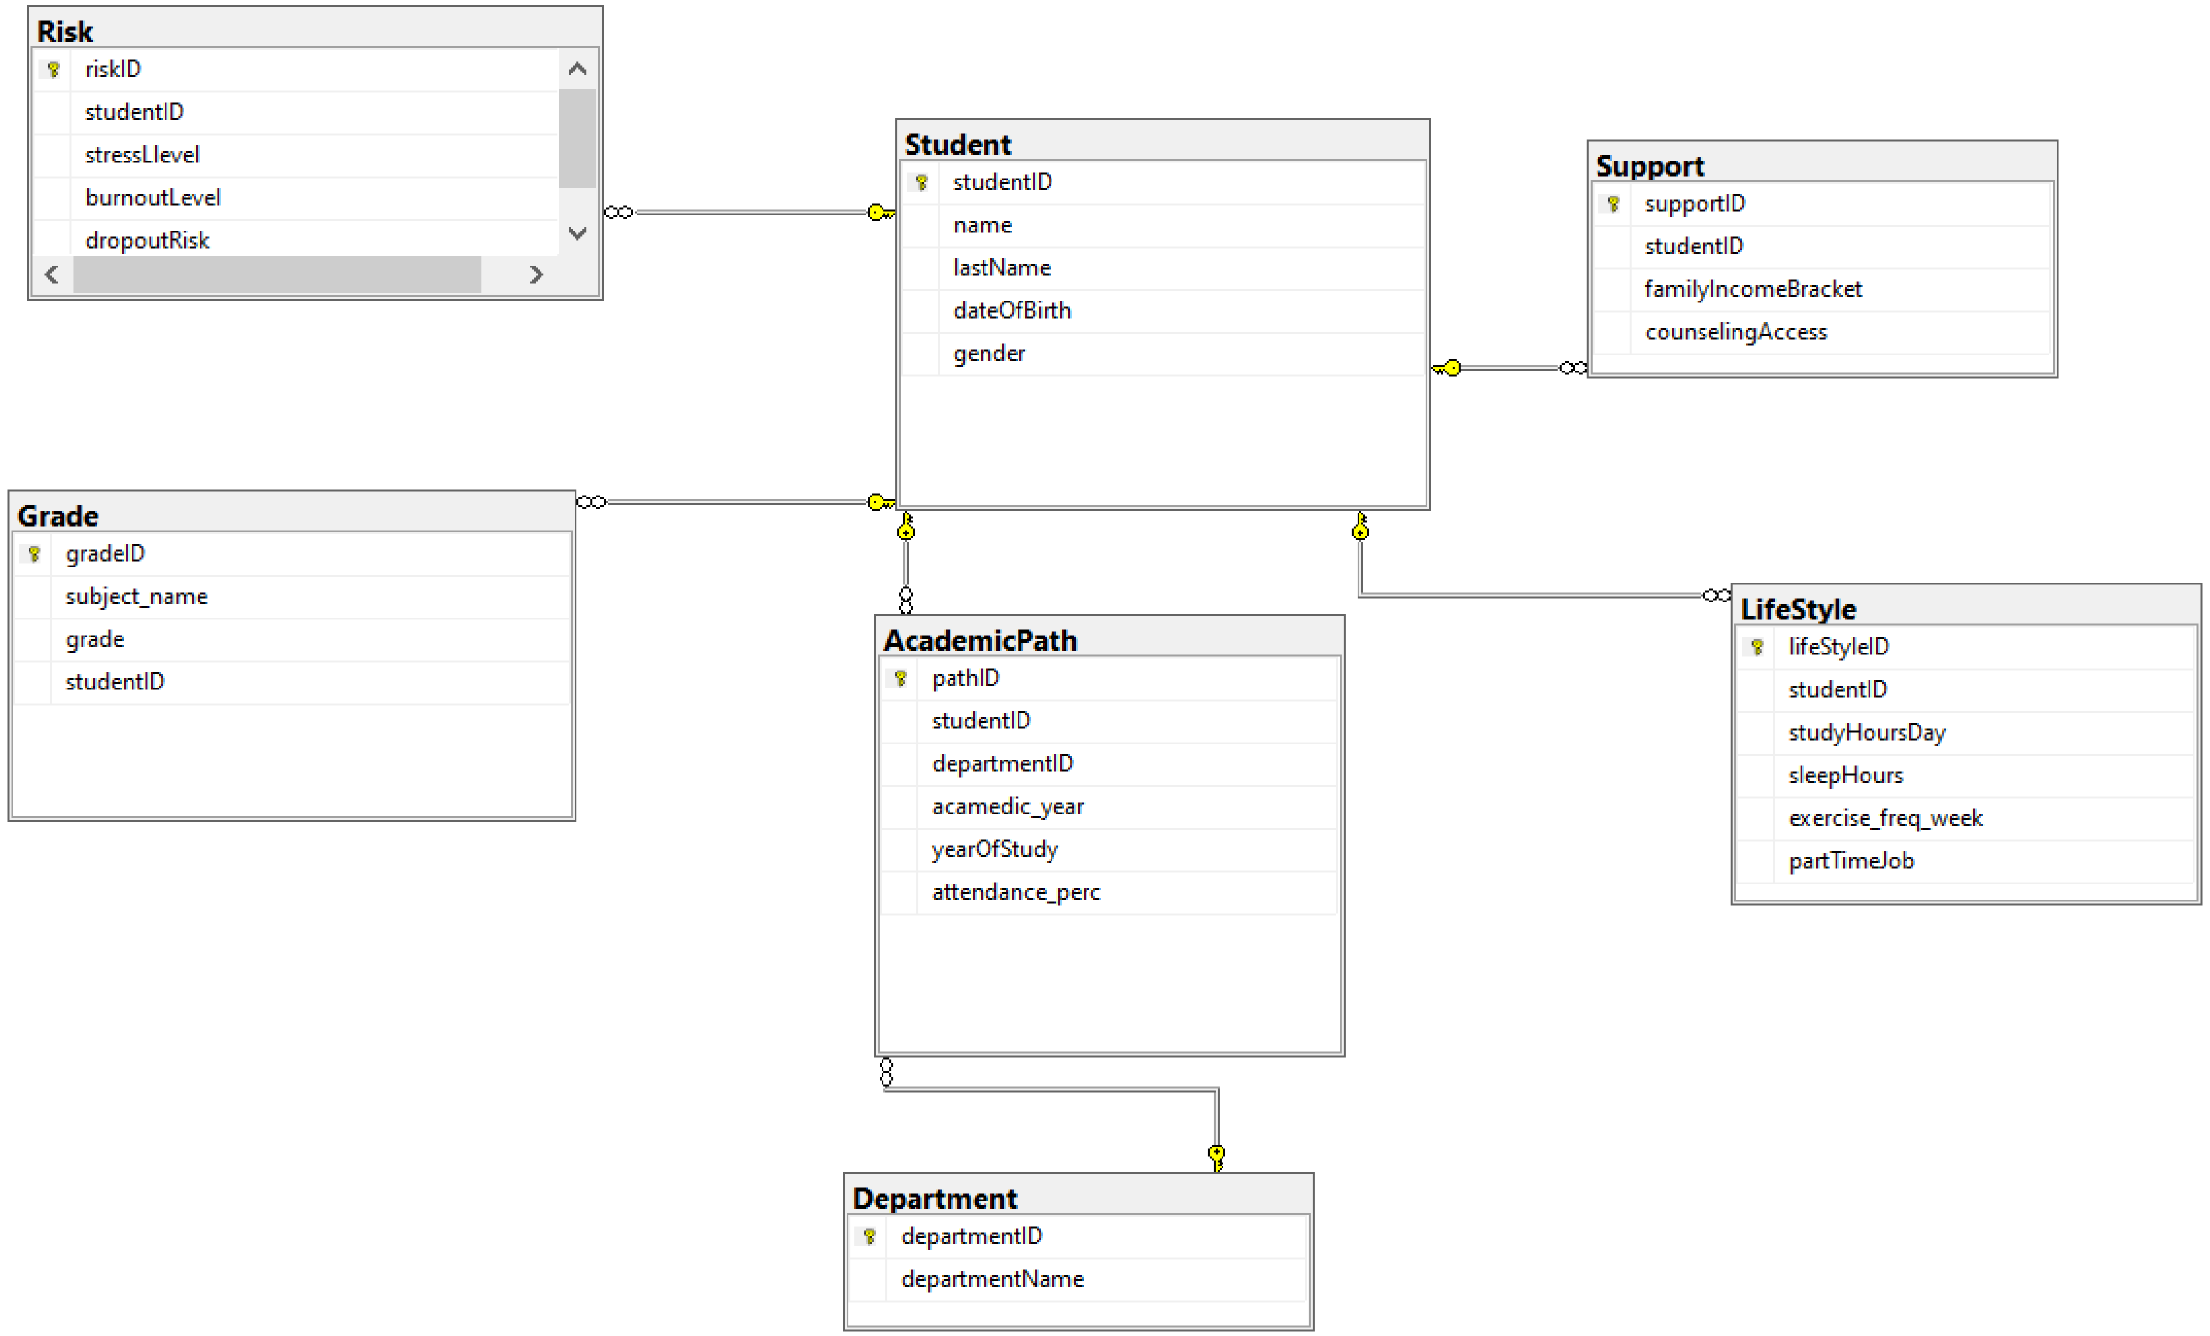

Pagina di risorse

Usa queste risorse nella tua presentazione Canva. Buon lavoro!
Ricorda di eliminare questa pagina prima della presentazione.

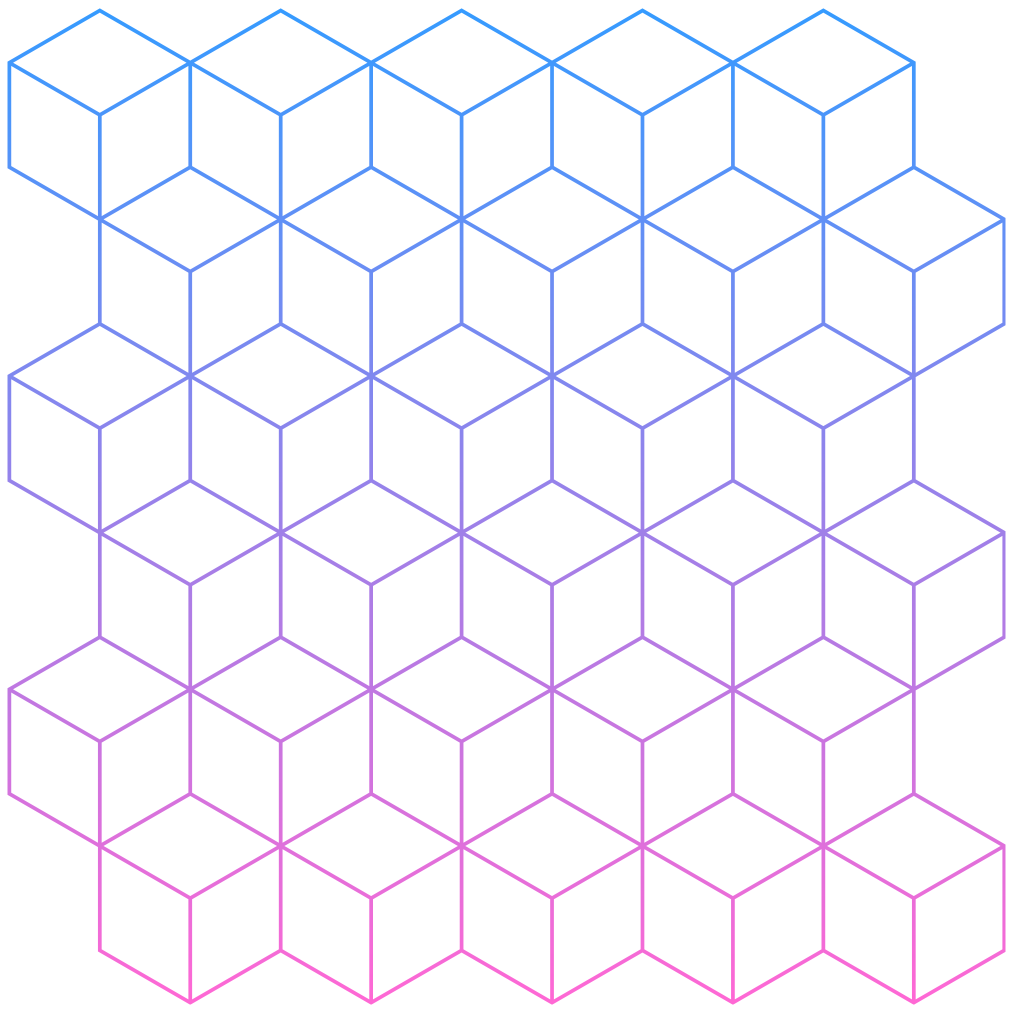

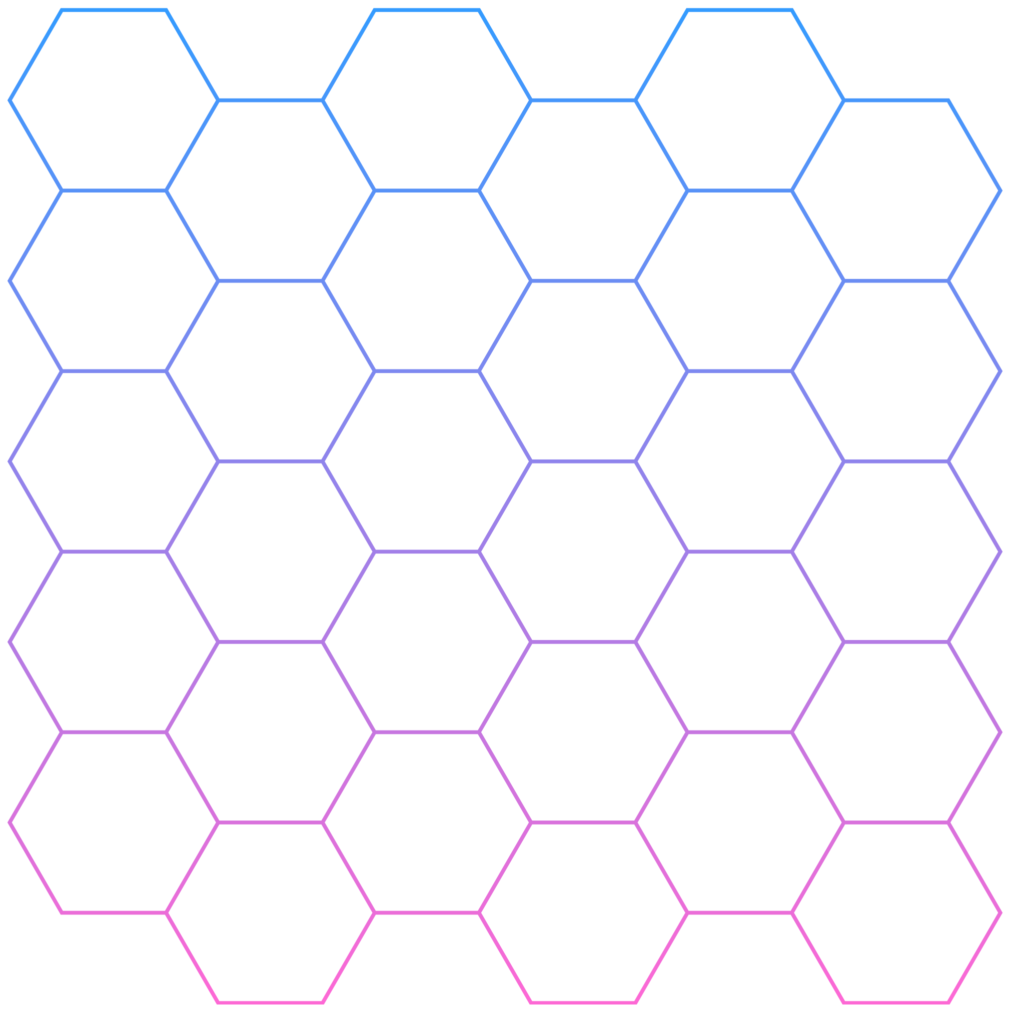

Grazie per l’attenzione!